Informe final — PrestaMatch

Inteligencia Artificial · UCSE 2026

El problema que teníamos que resolver

En PrestaMatch teníamos que decidir cuáles préstamos aprobar entre las solicitudes de enero de 2026, con un presupuesto máximo de USD 2.000.000. Si una persona devolvía el préstamo, ganábamos los intereses; si no pagaba, perdíamos el dinero prestado. Por eso nuestro objetivo no era aprobar la mayor cantidad posible, sino elegir los préstamos que nos permitieran obtener la mayor ganancia.

Los datos y cómo empezamos

Trabajamos con 32.416 solicitudes históricas de 2025, otras 3.061 solicitudes de enero de 2026 y un archivo con el historial bancario mensual de los clientes. Primero analizamos los montos solicitados, los ingresos, los intereses, los motivos de los préstamos y los atrasos en otras deudas.

Empezamos con una regresión logística sencilla que calculaba la probabilidad de que cada cliente pagara. La primera versión usaba principalmente el monto, la tasa de interés y el ingreso. Después incorporamos datos bancarios, como el saldo promedio y los atrasos anteriores a cada solicitud. Esto nos permitió conocer mejor el comportamiento de los clientes y mejoró mucho los resultados.

Los modelos y las pruebas que hicimos

A lo largo del trabajo probamos distintos modelos, como regresión logística, árboles de decisión, Random Forest, Gradient Boosting y KNN. En algunos casos modificamos sus configuraciones y las características utilizadas para intentar mejorar los resultados. Sin embargo, en nuestras pruebas ninguno logró superar la ganancia obtenida con la regresión logística, por lo que decidimos seguir mejorando ese modelo.

También incorporamos nuevas características, como la cantidad de atrasos de cada cliente, su comportamiento en los últimos meses, los cambios en sus saldos y la relación entre el préstamo solicitado y sus ingresos. Probamos distintas combinaciones, pero agregar más información no siempre significó obtener mejores resultados.

Cómo fuimos mejorando la selección

Al principio ordenábamos las solicitudes según la ganancia estimada de cada préstamo. Más adelante probamos priorizar la ganancia esperada por cada dólar prestado. Esta forma de elegir nos permitió aprovechar mejor el presupuesto en las pruebas realizadas. También encontramos que incluir el motivo del préstamo podía ayudar, aunque algunas mejoras dependían de pocos casos y no se repetían siempre.

Un problema que encontramos al evaluar

Al revisar los datos, notamos que los préstamos de enero eran mucho más pequeños que los utilizados para entrenar los modelos. Además, había clientes nuevos que no aparecían en las solicitudes anteriores. Por eso cambiamos la forma de realizar las pruebas: entrenamos con datos de los primeros meses y evaluamos con meses posteriores, teniendo en cuenta a los usuarios nuevos y los montos más parecidos a los de enero. También ajustamos el presupuesto de cada prueba para mantener una proporción similar entre el dinero disponible y el total solicitado. De esta manera, buscamos obtener resultados que representaran mejor las condiciones de la competencia.

La versión que elegimos

Finalmente nos quedamos con la V7, basada en regresión logística. Utilizamos información económica, el motivo del préstamo y datos del historial bancario, incluyendo atrasos y saldos recientes. Para entrenarla, nos concentramos en préstamos de hasta USD 10.900, que era el monto máximo presente en las solicitudes de enero.

Con las probabilidades calculadas, ordenamos los préstamos según la ganancia esperada por dólar y aprobamos los que parecían rentables sin superar el presupuesto. Antes de generar el archivo final comprobamos que estuvieran todas las solicitudes, que las decisiones fueran válidas y que el capital aprobado respetara el límite.

Resultados en Kaggle

Versión	Qué hicimos	Puntaje público
V1	Regresión logística con monto, interés e ingreso. Elegíamos por ganancia total esperada.	−USD 38.141,10
V2	Probamos ordenar la V1 por ganancia esperada por dólar. Fue una prueba interna.	No enviado
V3	Sumamos el historial bancario: saldos y atrasos anteriores del cliente.	USD 116.540,73
V4	Agregamos más información sobre atrasos: frecuencia y comportamiento reciente.	USD 127.544,77
V4 + motivo	Incorporamos el motivo del préstamo y elegimos por ganancia esperada por dólar.	USD 128.708,58
V5	Combinamos las probabilidades de regresión logística y Gradient Boosting.	No enviado
V6	Utilizamos un árbol de decisión con profundidad limitada.	No enviado
V7 (final)	Regresión logística ajustada, nuevas relaciones financieras e historial bancario; entrenamos con montos similares al test.	USD 130.062,00

La V7 aprobó 605 préstamos y utilizó USD 1.999.900 del presupuesto. Después de esa entrega seguimos probando algunos cambios, pero ninguno mostró una mejora suficientemente clara como para reemplazarla.